



INSTITUT
POLYTECHNIQUE
DE PARIS



ÉCOLE NATIONALE DES PONTS ET CHAUSSÉES

PROJET DE PREMIÈRE ANNÉE 2026

RAPPORT FINAL

Réduction de modèle : Proper Orthogonal Decomposition (POD) et méthode des bases réduites

Yasmine EL HOUARI, Antonin AYE, Mathis BORIE, Marek
PIOT

sous la direction de

Sofiane EZZEHI

CERMICS

Table des matières

1	Introduction	3
2	Problématique générale et modélisation	4
2.1	Problème physique : Les fluides et les écoulements de Darcy	4
2.2	Paramétrisation du problème	5
2.3	Formulation variationnelle	5
2.4	Discretisation par éléments finis (Modèle Haute Fidélité)	6
3	Réduction de modèle et hyper-réduction	7
3.1	L'ensemble d'entraînement	7
3.2	Extraction de la base réduite : La méthode POD	7
3.2.1	Principe géométrique et algébrique	7
3.2.2	Interprétation et propriétés des modes POD	8
3.3	Projection de Galerkin et modèle réduit	9
3.3.1	Formulation réduite	9
3.3.2	Analyse de l'erreur de projection	10
3.4	Limite de la POD seule : Le goulot d'assemblage	10
3.4.1	Complexité de la phase online et goulot d'étranglement	10
3.4.2	La solution : l'hypothèse de décomposition affine	11
3.5	Structure affine en les conductivités	11
3.5.1	Décomposition affine exacte à géométrie fixée	11
3.5.2	Séparation offline-online induite	12
3.5.3	Limite : la géométrie variable brise l'affinité	12
4	Hyper-réduction : EIM	13
4.1	Motivation	13
4.2	Méthode	13
4.2.1	Construction de la base EIM	13
4.2.2	"Magic points" et sélection greedy	14
4.2.3	Approximation affine et coefficients	15
4.3	Régularisation	16
4.3.1	L'obstacle de l'irrégularité	16
4.3.2	La fonction de Heaviside comme limite de la fonction sigmoïde	16
4.3.3	L'efficacité de l'EIM pour les fonctions lisses	17
5	Implémentation et validation numérique	17
5.1	Configuration du cas test paramétrique	18
5.1.1	Maillage et conditions aux limites	18
5.1.2	Espace des paramètres	18

5.2	Modèle Haute Fidélité et ensemble d'entraînement	19
5.3	Extraction de la base POD	21
5.3.1	Analyse spectrale	21
5.3.2	Interprétation physique des modes	22
5.4	Performances de la méthode POD (Phase Online)	23
5.4.1	Le goulot d'étranglement computationnel	24
5.4.2	Le cas de la dépendance affine	24
5.5	Hyper-réduction et performances EIM	26
5.5.1	Construction de la base EIM	26
5.5.2	Sélection des "magic points" et approximation de la conductivité . .	27
5.5.3	Régularisation	28
5.5.4	Performance finale de l'EIM	31
6	Conclusion	32
6.1	Résumé des résultats	32
6.2	Implications pratiques	33
6.3	Limitations et perspectives	33

1 Introduction

Les méthodes de réduction de modèle permettent d’approcher efficacement la solution d’un modèle numérique de grande dimension par un modèle de dimension beaucoup plus faible. Elles sont particulièrement utiles pour les équations aux dérivées partielles paramétrées, où l’on doit résoudre plusieurs fois un même problème pour différentes valeurs de paramètres. Dans ce cas, la méthode des éléments finis fournit une solution dite haute fidélité, précise, mais dont le calcul devient rapidement coûteux lorsque la discrétisation conduit à un système de grande taille.

Une approche classique consiste à chercher un espace réduit capable de représenter correctement l’ensemble des solutions possibles du problème. Cet espace peut être construit à partir de solutions haute fidélité calculées pour plusieurs valeurs des paramètres, appelées *snapshots*. Parmi les méthodes les plus utilisées, la *Proper Orthogonal Decomposition* (POD) permet d’extraire les directions principales de variation de ces snapshots. La solution est ensuite cherchée dans l’espace engendré par ces modes, et la projection de Galerkin permet d’obtenir un système réduit de petite taille. Cette stratégie permet donc de réduire fortement le coût de résolution du système linéaire.

Cependant, cette réduction de dimension ne suffit pas toujours. Pour que le modèle réduit soit réellement efficace, il faut également que l’assemblage du système réduit ne dépende plus de la dimension du modèle haute fidélité. Cela est possible lorsque les opérateurs du problème dépendent affinement des paramètres, car les différentes contributions peuvent alors être préassemblées une fois pour toutes en phase *offline*. En revanche, lorsque cette dépendance est non affine, l’assemblage en phase *online* peut encore nécessiter des opérations sur tout le maillage, ce qui limite le gain obtenu par la réduction de modèle. C’est dans ce contexte que les méthodes d’hyper-réduction, comme l’*Empirical Interpolation Method* (EIM), deviennent nécessaires : elles permettent d’approximer les termes non affines par une décomposition affine approchée, compatible avec une séparation *offline-online* efficace.

Dans ce rapport, nous étudions un problème d’écoulement de Darcy dans un milieu poreux fracturé. Le domaine considéré est le carré unité, discrétisé par éléments finis, et l’inconnue principale est le champ de pression du fluide. La conductivité du milieu dépend de plusieurs paramètres décrivant la fracture, notamment sa pente, sa position et sa largeur, ainsi que les conductivités du milieu de fond et de la fracture. La dépendance en certains paramètres est affine, tandis que la dépendance géométrique liée à la fracture est non affine, ce qui motive l’utilisation d’une méthode d’hyper-réduction.

Les objectifs de ce rapport sont les suivants :

- **Modéliser et résoudre le problème de Darcy haute fidélité**, en présen-

tant la formulation variationnelle, la discrétisation par éléments finis et le rôle des paramètres de conductivité.

- **Construire un modèle réduit par POD-Galerkin**, à partir de snapshots du modèle haute fidélité, puis évaluer sa précision selon le nombre de modes conservés.
- **Analyser la limite du modèle réduit classique**, lorsque la dépendance non affine de la conductivité impose encore un assemblage coûteux sur le maillage complet.
- **Introduire l'EIM pour obtenir une hyper-réduction efficace**, puis comparer les approches en termes de temps de calcul et d'erreur.

2 Problématique générale et modélisation

2.1 Problème physique : Les fluides et les écoulements de Darcy

En physique, un fluide sous pression traversant un milieu poreux cherche toujours à minimiser son énergie. Tout comme une bille dévale une pente pour atteindre le point le plus bas, un fluide va naturellement s'écouler en empruntant le chemin de moindre résistance pour dissiper le moins d'énergie possible.

Le fluide se déplace sous l'effet d'un gradient de pression ∇u , où u désigne la pression. Cependant, le fluide ne s'écoule pas dans le vide : il frotte contre les parois du milieu. La vitesse d'écoulement du fluide, notée $\mathbf{v}$, est dictée par la loi empirique de Darcy [1] : $\mathbf{v} = -k\nabla u$, où k est un coefficient empirique qui dépend du fluide et du milieu.

L'énergie volumique dissipée localement par ce frottement visqueux correspond au travail de cette vitesse contre le gradient de pression, valant ainsi $\frac{1}{2}k\nabla u \cdot \nabla u$. En opposition à cette perte d'énergie, on peut considérer le travail fourni au système par une source externe de fluide (comme un puits d'injection ou de pompage), modélisée par un terme f .

Le principe de minimisation de l'énergie revient alors à chercher le champ de pression u qui minimise la fonctionnelle $J(u)$ totale sur le domaine étudié Ω :

$$J(u) = \int_{\Omega} \frac{1}{2}k\nabla u \cdot \nabla u \, d\Omega - \int_{\Omega} f u \, d\Omega,$$

La condition du premier ordre pour minimiser cette énergie impose que sa dérivée s'annule. En appliquant une intégration par parties à cette condition, le problème se sépare mathématiquement en deux composantes. Pour que l'équilibre soit garanti, le fluide doit vérifier une équation différentielle locale à l'intérieur du domaine Ω , et simultanément respecter les contraintes imposées sur les bords $\partial\Omega$ (par exemple, une pression imposée $\bar{u}$,

appelée condition de Dirichlet). On obtient ainsi le système complet [1] :

$$\begin{cases} -\nabla \cdot (k \nabla u) = f & \text{dans } \Omega \\ u = \bar{u} & \text{sur } \partial\Omega \end{cases}$$

2.2 Paramétrisation du problème

L'enjeu de ce projet réside dans la dépendance de la solution u vis-à-vis d'un vecteur de paramètres μ appartenant à un espace admissible $\mu_{\text{ad}} \subset \mathbb{R}^P$. Ces paramètres dictent la structure du milieu.

On considère un milieu hétérogène composé d'un matériau de fond (*background*) et d'une inclusion géométrique (*fracture*). La conductivité k est définie par une fonction spatiale dépendant de paramètres géométriques (position, orientation, épaisseur) et des propriétés physiques des matériaux :

$$k(x, y; \mu) = D_{\text{back}} + (D_{\text{frac}} - D_{\text{back}}) \cdot \mathcal{H}(\mathcal{D}(x, y; \mu_{\text{geo}}))$$

où $\mathcal{D}$ représente la distance signée à l'inclusion et $\mathcal{H}$ est une fonction caractéristique délimitant la fracture. Cette formulation induit une dépendance *affine* vis-à-vis des valeurs de conductivité physique ($D_{\text{back}}, D_{\text{frac}}$) mais une dépendance fortement *non-linéaire* vis-à-vis des paramètres géométriques.

2.3 Formulation variationnelle

Dans la suite du projet nous considérons le domaine $\Omega = [0, 1]^2$, et nous nous intéresserons au problème suivant :

Trouver $u \in H^1(\Omega)$ tel que :

$$\begin{cases} -\nabla \cdot (k \nabla u) = 0 & \text{dans } \Omega, \\ u = \bar{u} & \text{sur } \partial\Omega. \end{cases} \quad (1)$$

où $k \in L^\infty(\Omega)$ est le coefficient de conductivité, supposé uniformément borné et strictement positif (condition d'ellipticité), et $\bar{u} \in H^1(\partial\Omega)$ est la donnée de Dirichlet sur la frontière, correspondant à la trace sur $\partial\Omega$ d'une fonction de $H^1(\Omega)$.

Pour résoudre ce problème, on utilise une technique de relèvement. Soit $u_L \in H^1(\Omega)$ tel que $u_L|_{\partial\Omega} = \bar{u}$. On peut alors chercher des champs de pression $u_0 \in H_0^1(\Omega)$ tels que $u = u_0 + u_L$ soit solution du problème (1). Cela permet de poser la formulation variationnelle suivante :

Trouver $u_0 \in H_0^1(\Omega)$ tel que :

$$a(u_0, v) = L(v) \quad \forall v \in H_0^1(\Omega)$$

où les formes bilinéaire et linéaire sont définies par :

$$a(u_0, v) = \int_{\Omega} k(x, y; \mu) \nabla u_0 \cdot \nabla v \, d\Omega, \quad (2)$$

$$L(v) = - \int_{\Omega} k(x, y; \mu) \nabla u_L \cdot \nabla v \, d\Omega. \quad (3)$$

Sous cette forme, le terme de droite $L(v)$ représente l'influence des conditions aux limites imposées sur le système.

La forme bilinéaire $a(\cdot, \cdot)$ est continue et coercive :

$$\text{Continuité : } |a(u, v)| \leq \|k\|_{\infty} \|u\|_{H^1} \|v\|_{H^1} \quad (4)$$

$$|L(v)| \leq \|k\|_{\infty} \|u_L\|_{H^1} \|v\|_{H^1} \quad (5)$$

$$\text{Coercivité : } a(u, u) \geq \|k\|_{\min} \|u\|_{H^1}^2 \quad (6)$$

avec $\|k\|_{\min} = \min(D_{\text{back}}, D_{\text{frac}}) > 0$ et $\|k\|_{\max} = \max(D_{\text{back}}, D_{\text{frac}})$.

Par le **théorème de Lax-Milgram**, il existe une unique solution $u' \in H_0^1(\Omega)$ satisfaisant la formulation variationnelle, et donc une solution $u \in H^1(\Omega)$ au problème original.

2.4 Discrétisation par éléments finis (Modèle Haute Fidélité)

La solution exacte appartenant à un espace de dimension infinie, on approche le problème par la méthode des éléments finis. On introduit un espace de dimension finie $V_h \subset H^1(\Omega)$, composé de polynômes de Lagrange de degré d . Le problème discret consiste à chercher $u_h \in V_h$ tel que :

$$a(u_h, v_h; \mu) = L(v_h; \mu) \quad \forall v_h \in V_{h,0}$$

En choisissant une base $\{\phi_i\}_{i=1}^{N_{\text{dof}}}$ de l'espace V_h , le problème se ramène à la résolution d'un système linéaire :

$$A(\mu) \mathbf{u}_h(\mu) = \mathbf{b}(\mu)$$

où $A(\mu)$ est la matrice de rigidité et $\mathbf{b}(\mu)$ le vecteur de charge. En résolvant le système on obtient la solution $\mathbf{u}_h(\mu)$ qui constitue la solution **Haute Fidélité** (HDM).

3 Réduction de modèle et hyper-réduction

La résolution du modèle haute fidélité pour un grand nombre de valeurs du paramètre μ est prohibitive : à chaque nouvelle configuration, il faut réassembler et résoudre un système linéaire creux de taille N_{dof} . Ce coût, incompressible dans le cadre haute fidélité, interdit toute utilisation en contexte d'optimisation paramétrique, d'inversion, ou de simulation temps-réel.

L'objectif de la **réduction de modèle** est de construire un substitut de faible dimension, le modèle réduit, qui reproduit fidèlement le comportement du modèle haute fidélité pour tout $\mu \in \mu_{\text{ad}}$, à un coût numérique drastiquement inférieur. Cette construction repose sur une phase *offline* coûteuse, réalisée une seule fois, et une phase *online* ultra-rapide, répétée pour chaque nouvelle valeur de μ .

3.1 L'ensemble d'entraînement

Pour construire le modèle réduit, on échantillonne N_s solutions du modèle haute fidélité en variant aléatoirement les paramètres dans l'espace admissible μ_{ad} . Chaque snapshot $\mathbf{u}_h(\mu^{(i)}) \in \mathbb{R}^{N_{\text{dof}}}$ constitue une solution complète du problème haute fidélité pour un jeu de paramètres donné.

L'ensemble d'entraînement ainsi constitué est :

$$\mathcal{S} = \left\{ \mathbf{u}_h(\mu^{(i)}) \right\}_{i=1}^{N_s} \subset \mathbb{R}^{N_{\text{dof}}}$$

Bien que chaque solution soit différente, elles possèdent de nombreux points communs liés à la géométrie du problème. Ces ressemblances suggèrent qu'il n'est pas nécessaire de conserver les N_{dof} degrés de liberté pour obtenir des solutions acceptables, ce qui motive l'approche par réduction de modèle.

3.2 Extraction de la base réduite : La méthode POD

3.2.1 Principe géométrique et algébrique

La méthode POD (Proper Orthogonal Decomposition) cherche à extraire les directions principales de variation des solutions, permettant d'approcher au mieux l'ensemble des snapshots dans un sous-espace de faible dimension. On assemble une matrice dont chaque colonne est une solution complète du problème :

$$U = [\mathbf{u}_h(\mu^{(1)}), \mathbf{u}_h(\mu^{(2)}), \dots, \mathbf{u}_h(\mu^{(N_s)})] \in \mathbb{R}^{N_{\text{dof}} \times N_s}$$

On effectue alors une Décomposition en Valeurs Singulières (SVD) de cette matrice de snapshots :

$$U = \tilde{U}\Sigma V^T$$

Ici, $\tilde{U} \in \mathbb{R}^{N_{\text{dof}} \times N_s}$ contient les **modes de la POD**. Le **théorème d'Eckart-Young** garantit que le sous-espace vectoriel de dimension r permettant d'approcher au mieux l'ensemble des colonnes de la matrice U pour la norme 2, est l'espace engendré par les r premières colonnes de $\tilde{U}$. Ces vecteurs constituent une base orthogonale de l'espace réduit et représentent les directions principales dans lesquelles se projettent les données.

Σ est une matrice diagonale de **valeurs singulières** $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{N_s} \geq 0$, ordonnées par importance décroissante. Les valeurs singulières fournissent une mesure directe de l'énergie contenue dans chaque mode POD. Plus précisément, la fraction d'énergie totale capturée par les premiers r modes est donnée par :

$$E(r) = \frac{\sum_{i=1}^r \sigma_i^2}{\sum_{i=1}^{N_s} \sigma_i^2}$$

Cette fraction d'énergie indique dans quelle mesure les premiers modes suffisent à représenter l'ensemble des données originales. En pratique, un choix judicieux du nombre de modes r permet d'obtenir une bonne approximation tout en réduisant la complexité du modèle. On observe expérimentalement que les premières valeurs singulières décroissent très rapidement (phénomène du "coude", ou *elbow effect*), ce qui justifie la troncature à un petit nombre de modes.

On construit donc la base réduite en tronquant :

$$V_r = [\tilde{U}_{:,1}, \tilde{U}_{:,2}, \dots, \tilde{U}_{:,r}] \in \mathbb{R}^{N_{\text{dof}} \times r}$$

3.2.2 Interprétation et propriétés des modes POD

Les modes POD $\phi_i = \tilde{U}_{:,i}$ sont hiérarchisés par l'énergie qu'ils contiennent. Le premier mode capture la structure spatiale prédominante, c'est-à-dire la "tendance de fond" commune à tous les écoulements de notre dataset. Les modes suivants (2, 3, ...) viennent y ajouter des détails et des corrections de plus en plus fins, spécifiquement nécessaires pour capturer les déviations causées par la géométrie variable de la fracture.

Cette base orthonormée empirique est ce qui permet de compresser les données de façon optimale : toute solution paramétrique peut s'écrire comme une combinaison linéaire de ces briques élémentaires. On réduit ainsi le problème de la recherche de N_{dof} valeurs nodales à la recherche de seulement $r \ll N_{\text{dof}}$ coefficients de contribution.

3.3 Projection de Galerkin et modèle réduit

3.3.1 Formulation réduite

Une fois la base V_r construite, on projette le problème variationnel complet sur ce sous-espace de faible dimension. Plutôt que de chercher $\mathbf{u}_h \in \mathbb{R}^{N_{\text{dof}}}$, on cherche maintenant $\mathbf{c}(\mu) \in \mathbb{R}^r$ tel que :

$$A_r(\mu)\mathbf{c}(\mu) = \mathbf{b}_r(\mu)$$

où :

$$A_r(\mu) = V_r^T A(\mu) V_r \in \mathbb{R}^{r \times r} \quad (7)$$

$$\mathbf{b}_r(\mu) = V_r^T \mathbf{b}(\mu) \in \mathbb{R}^r \quad (8)$$

La solution réduite est reconstruite simplement par :

$$\mathbf{u}_r(\mu) = V_r \mathbf{c}(\mu)$$

Remarque : Si l'on définit le *produit scalaire* et la *norme* associés à la matrice symétrique définie positive $A(\mu)$:

$$\langle x, y \rangle_{A(\mu)} = x^T A(\mu) y \quad (9)$$

$$\|x\|_{A(\mu)} = \sqrt{\langle x, x \rangle_{A(\mu)}} = \sqrt{x^T A(\mu) x} \quad (10)$$

La projection de Galerkin minimise cette norme associée à la matrice de rigidité $A(\mu)$, et donc ne minimise pas nécessairement la norme L_2 :

$$V_r^T A(\mu) \mathbf{u}_r(\mu) = A_r(\mu) \mathbf{c}(\mu) = \mathbf{b}_r(\mu) \quad (11)$$

$$= V_r^T \mathbf{b}(\mu) \quad (12)$$

$$= V_r^T A(\mu) \mathbf{u}_h(\mu) \quad (13)$$

On en déduit :

$$0_r = V_r^T A(\mu) (\mathbf{u}_r(\mu) - \mathbf{u}_h(\mu)) \quad (14)$$

Par caractérisation du projeté orthogonal, $\mathbf{u}_r(\mu)$ est la projection orthogonale de $\mathbf{u}_h(\mu)$ sur l'espace engendré par les colonnes de V_r pour le produit scalaire induit par $A(\mu)$ (et non pas pour le produit scalaire L_2).

3.3.2 Analyse de l'erreur de projection

L'erreur introduite par la réduction est quantifiée en comparant la solution POD $\mathbf{u}_r(\mu)$ à la solution de référence $\mathbf{u}_h(\mu)$. On évalue cette précision à travers **L'erreur relative en norme énergétique** (A-norme) : $e_A = \frac{\|u_h - u_r\|_{A(\mu)}}{\|u_h\|_{A(\mu)}}$.

Remarque : la norme d'énergie est équivalente à la norme L_2 :

$$\lambda_{\min} \|u\|_{L^2}^2 \leq \|u\|_{A(\mu)}^2 \leq \lambda_{\max} \|u\|_{L^2}^2$$

où $\lambda_{\min}$ et $\lambda_{\max}$ sont les valeurs propres extrêmes de la matrice $A(\mu)$. Cependant, l'erreur en norme énergétique est plus pertinente pour évaluer la qualité de la projection de Galerkin, car c'est précisément cette norme que la projection de Galerkin minimise. Nous utiliserons donc la norme d'énergie pour étudier les performances d'algorithme reposant sur une projection de Galerkin.

En vertu du théorème d'Eckart-Young, l'erreur de projection est directement bornée par le reste des valeurs singulières tronquées (celles exclues de la base). Pour des problèmes elliptiques paramétriques réguliers comme le nôtre, l'ensemble des solutions est très régulier vis-à-vis des paramètres, ce qui se traduit par une chute brutale (souvent exponentielle) des valeurs singulières. Par conséquent, l'erreur relative s'effondre très rapidement à mesure que l'on augmente r , garantissant l'efficacité de la méthode POD.

3.4 Limite de la POD seule : Le goulot d'assemblage

3.4.1 Complexité de la phase online et goulot d'étranglement

La projection de Galerkin réduit le coût de *résolution* du système de $\mathcal{O}(N_{\text{dof}}^{3/2})$ à $\mathcal{O}(r^3)$. Toutefois, en phase *online*, chaque changement du paramètre μ exige de reconstruire la matrice réduite $A_r(\mu) = V_r^T A(\mu) V_r$. Cela implique deux étapes coûteuses :

1. **L'assemblage de la matrice $A(\mu)$** : Bien que cette matrice soit creuse grâce au support local des éléments finis, le calcul des intégrales de conductivité sur chaque élément du maillage impose un coût proportionnel à la taille de ce dernier, soit $\mathcal{O}(N_{\text{dof}})$.
2. **La projection de Galerkin** : La multiplication de $A(\mu)$ par la base dense V_r ajoute une complexité de $\mathcal{O}(r^2 N_{\text{dof}})$.

La phase *online* est donc dominée par ce coût en $\mathcal{O}(r^2 N_{\text{dof}})$. Malgré $r \ll N_{\text{dof}}$, cette dépendance *linéaire* à la taille du maillage constitue le véritable goulot d'étranglement computationnel : le temps d'exécution du modèle réduit reste "esclave" de la finesse du modèle haute fidélité.

3.4.2 La solution : l'hypothèse de décomposition affine

Pour briser cette dépendance et rendre la phase *online* véritablement indépendante de N_{dof} , il faut pouvoir former $A_r(\mu)$ sans jamais avoir à instancier $A(\mu)$ en entier. Ceci est mathématiquement possible si la matrice $A(\mu)$ (et par extension la conductivité k) admet une **décomposition affine** par rapport aux paramètres. Il s'agit de trouver des fonctions scalaires $\theta_q : \mu_{\text{ad}} \rightarrow \mathbb{R}$ et des matrices $A^{(q)}$ indépendantes de μ telles que :

$$A(\mu) = \sum_{q=1}^Q \theta_q(\mu) A^{(q)}$$

Si cette propriété est vérifiée, on peut alors pré-calculer les projections réduites $A_r^{(q)} = V_r^T A^{(q)} V_r$ une unique fois lors de la phase *offline*. En phase *online*, la matrice réduite finale s'obtient par une simple combinaison linéaire de ces petites matrices :

$$A_r(\mu) = \sum_{q=1}^Q \theta_q(\mu) A_r^{(q)}$$

Cette opération ne coûte plus que $\mathcal{O}(Qr^2)$ opérations, un temps de calcul strictement décorrélé de N_{dof} . Toute la question qui se pose pour la suite de ce projet est donc de savoir si notre conductivité paramétrée $k(x, y; \mu)$ possède nativement cette structure affine, ou s'il faudra l'approcher de manière empirique.

3.5 Structure affine en les conductivités

3.5.1 Décomposition affine exacte à géométrie fixée

Lorsque la géométrie de la fracture est fixée, c'est-à-dire lorsque (a, x_0, w) sont donnés, la fonction de conductivité $k(x, y; \mu)$ est une fonction **linéaire** des deux paramètres scalaires D_{back} et D_{frac} . En effet, on peut réécrire :

$$\begin{aligned} k(x, y; \mu) &= D_{\text{back}} + (D_{\text{frac}} - D_{\text{back}}) \cdot H(\mathcal{D}(x, y)) \\ &= D_{\text{back}} \underbrace{\left(1 - H(\mathcal{D}(x, y))\right)}_{k^{(1)}(x, y)} + D_{\text{frac}} \underbrace{H(\mathcal{D}(x, y))}_{k^{(2)}(x, y)} \end{aligned} \quad (15)$$

où $k^{(1)}(x, y) = 1 - H(\mathcal{D})$ et $k^{(2)}(x, y) = H(\mathcal{D})$ sont deux fonctions spatiales **indépendantes de μ** (puisque la géométrie est fixée). On obtient ainsi une décomposition affine exacte avec $Q_a = 2$ termes :

$$k(x, y; \mu) = \theta_1(\mu) k^{(1)}(x, y) + \theta_2(\mu) k^{(2)}(x, y), \quad \theta_1 = D_{\text{back}}, \quad \theta_2 = D_{\text{frac}}$$

Cette décomposition se propage directement à la matrice de rigidité :

$$A(\mu) = D_{\text{back}} A^{(1)} + D_{\text{frac}} A^{(2)}$$

où les matrices $A^{(1)}, A^{(2)} \in \mathbb{R}^{N_{\text{dof}} \times N_{\text{dof}}}$ sont définies par :

$$A_{ij}^{(q)} = \int_{\Omega} k^{(q)}(x, y) \nabla \phi_i \cdot \nabla \phi_j d\Omega, \quad q \in \{1, 2\}$$

et ne dépendent que de la géométrie fixée, pas de $(D_{\text{back}}, D_{\text{frac}})$.

3.5.2 Séparation offline-online induite

La décomposition affine permet une séparation stricte du coût de calcul.

Phase offline : On assemble une fois pour toutes les deux matrices $A^{(1)}$ et $A^{(2)}$, puis on calcule leurs projections réduites :

$$A_r^{(1)} = V_r^T A^{(1)} V_r \in \mathbb{R}^{r \times r}, \quad A_r^{(2)} = V_r^T A^{(2)} V_r \in \mathbb{R}^{r \times r}$$

Ce calcul, de coût $\mathcal{O}(N_{\text{dof}} \cdot r)$, n'est effectué qu'une seule fois.

Phase online : Pour chaque nouveau couple $(D_{\text{back}}, D_{\text{frac}})$, la matrice réduite s'obtient sans aucun accès au maillage :

$$A_r(\mu) = D_{\text{back}} A_r^{(1)} + D_{\text{frac}} A_r^{(2)}$$

Cette combinaison linéaire coûte $\mathcal{O}(r^2)$, entièrement indépendant de N_{dof} .

3.5.3 Limite : la géométrie variable brise l'affinité

Dès que les paramètres géométriques (a, x_0, w) varient, la position et l'orientation de la fracture changent. Les fonctions $k^{(1)}$ et $k^{(2)}$ dépendent alors elles-mêmes de μ , et ne peuvent plus être préassemblées en phase offline. La décomposition affine exacte à deux termes n'est plus disponible.

Plus généralement, on peut montrer qu'aucune décomposition exacte avec un nombre fini Q de termes ne peut représenter la famille paramétrée $\{H(\mathcal{D}(\cdot; a, x_0, w))\}_{(a, x_0, w)}$: pour chaque configuration géométrique, la Heaviside est supportée sur un demi-espace différent, et l'espace engendré par ces fonctions est de dimension infinie. Il faut donc construire une **approximation affine**, ce qui fera l'objet de la Section 4.

Sans une décomposition affine du terme de conductivité $k(x, y; \mu)$, le modèle réduit reste "esclave" de la finesse du maillage haute fidélité, ce qui motive l'utilisation de l'hyper-réduction (EIM).

4 Hyper-réduction : EIM

4.1 Motivation

La projection de Galerkin réduit la dimension du problème de N_{dof} à r , ce qui accélère la résolution du système linéaire. Cependant, elle ne résout pas le goulot d’assemblage : pour chaque évaluation paramétrique, on doit toujours assembler la matrice complète $A(\mu)$ en $\mathcal{O}(N_{\text{dof}})$ opérations.

L’**Empirical Interpolation Method (EIM)** est une technique d’hyper-réduction destinée à contourner ce problème. Comme pour l’espace des solutions, nous pouvons à l’aide d’une POD trouver une base $\{q_m\}$ permettant d’approcher la conductivité :

$$k(x, y; \mu) \approx \sum_{m=1}^M \beta_m(\mu) q_m(x, y)$$

où les $\beta_m(\mu)$ sont des coefficients dépendant du paramètre (μ) et les $q_m(x, y)$ sont des fonctions spatiales pré-calculées, alors on peut assembler en phase offline les matrices de rigidité associées aux éléments de cette base :

$$A_r^{(m)} = V_r^T A^{(m)} V_r \quad (\text{une seule fois par mode EIM})$$

et former en phase online :

$$A_r(\mu) = \sum_{m=1}^M \beta_m(\mu) A_r^{(m)} \quad (\text{temps négligeable})$$

Le principal enjeu de la méthode est donc de déterminer les $\beta_m(\mu)$ sans avoir besoin de faire une projection de k sur les éléments de la base $\{q_m\}$, opération qui serait en $\mathcal{O}(N_{\text{dof}})$.

4.2 Méthode

4.2.1 Construction de la base EIM

Pour construire une approximation affine, on commence par collecter des snapshots de la conductivité k sur un ensemble d’entraînement :

$$G = [k(\cdot, \cdot; \mu^{(1)}), k(\cdot, \cdot; \mu^{(2)}), \dots, k(\cdot, \cdot; \mu^{(N_G)})] \in \mathbb{R}^{N_{\text{dof}} \times N_G}$$

On applique la Décomposition en Valeurs Singulières (SVD) :

$$G = U_G \Sigma_G V_G^T$$

Les M premiers vecteurs singuliers :

$$q_m = (U_G)_{:,m} \quad \text{pour } m = 1, \dots, M$$

forment la base EIM que l'on utilisera pour approximer les fonctions de conductivité.

4.2.2 "Magic points" et sélection greedy

Comme souligné précédemment, nous avons maintenant une base orthonormale $\{q_m\}_{i=1}^M$ pour approximer k , mais n'avons aucun moyen de calculer les coefficients $\beta_m(\mu)$ sans faire une projection complète, ce qui est en $\mathcal{O}(N_{\text{dof}})$.

La solution proposée par l'EIM pour répondre à ce problème repose sur le fait que pour des fonctions *suffisamment régulières*, des informations locales peuvent permettre de comprendre des comportements globaux.

Ainsi, l'EIM propose un algorithme glouton (greedy algorithm) pour sélectionner M "magic points" $\{t_1, t_2, \dots, t_M\}$ parmi les N_{dof} noeuds du maillage possédant les propriétés suivantes :

1. **Unicité de l'interpolation [3]** : Pour toute fonction de conductivité k , il existe une unique interpolation $\mathcal{I}_M[k]$ de k sur la base $\{q_m\}_{i=1}^M$ tel que $\mathcal{I}_M[k](t_m) = k(t_m)$ pour tout "magic point" t_m . Les coefficients $\beta_m(\mu)$ peuvent ainsi être déterminés uniquement à partir des valeurs de k aux "magic points".
2. **Contrôle de l'erreur globale [3]** :

$$\|k - \mathcal{I}_M[k]\|_{L^\infty} \leq (1 + \Lambda_M) \inf_{v \in V_M} \|k - v\|_{L^\infty} \quad (16)$$

où $\inf_{v \in V_M} \|k - v\|_{L^\infty}$ représente la distance pour la norme L^∞ entre k et l'espace engendré par les modes q_m , et Λ_M est la **constante de Lebesgue** associée à l'espace V_M et aux "magic points".

Remarque : La norme L^∞ domine la norme L^2 sur un domaine de mesure finie. De plus si l'on travaille avec des fonctions *suffisamment régulières*, $(1 + \Lambda_M) \inf_{v \in V_M} \|k - v\|_{L^\infty}$ décroît de manière exponentielle avec M , garantissant très vite une approximation de haute qualité.

L'algorithme de sélection glouton [3] :

1. **Initialisation** : $t_1 = \arg \max_j |q_1(j)|$ (noeud du maillage où $|q_1|$ atteint son maximum).
2. **Itération pour** $m = 2, \dots, M$:

(a) Construire la matrice d'interpolation :

$$Z_m = \begin{pmatrix} q_1(t_1) & q_2(t_1) & \cdots & q_{m-1}(t_1) \\ q_1(t_2) & q_2(t_2) & \cdots & q_{m-1}(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ q_1(t_{m-1}) & q_2(t_{m-1}) & \cdots & q_{m-1}(t_{m-1}) \end{pmatrix} \in \mathbb{R}^{(m-1) \times (m-1)}$$

(b) Résoudre le système $Z_m \mathbf{c} = [q_m(t_1), \dots, q_m(t_{m-1})]^T$ pour obtenir les coefficients $\mathbf{c}$.

(c) Calculer l'erreur d'approximation du mode q_m à chaque nœud du maillage :

$$e_j = \left| q_m(j) - \sum_{\ell=1}^{m-1} c_\ell q_\ell(j) \right|$$

(d) Sélectionner le point où l'erreur est maximale :

$$t_m = \arg \max_j e_j$$

On dispose alors d'une matrice d'interpolation finale $Z_M \in \mathbb{R}^{M \times M}$ et d'un ensemble de "magic points" $\{t_1, \dots, t_M\}$.

4.2.3 Approximation affine et coefficients

Les coefficients $\beta_m(\mu)$ sont déterminés par interpolation :

$$\beta(\mu) = Z_M^{-1} \mathbf{k}_{\text{magic}}(\mu)$$

où $\mathbf{k}_{\text{magic}}(\mu) = [k(t_1; \mu), k(t_2; \mu), \dots, k(t_M; \mu)]^T$ est le vecteur des valeurs de conductivité évaluées uniquement aux "magic points".

Complexité : Évaluer $\mathbf{k}_{\text{magic}}(\mu)$ coûte $\mathcal{O}(M)$ opérations (au lieu de $\mathcal{O}(N_{\text{dof}})$), ce qui est l'amélioration cruciale.

Ainsi, la conductivité peut être approximée par :

$$k(x, y; \mu) \approx \sum_{m=1}^M \beta_m(\mu) q_m(x, y)$$

Nous avons ainsi construit une approximation affine de la conductivité, permettant de former la matrice réduite $A_r(\mu)$ en temps $\mathcal{O}(Mr^2)$. La phase *online* complète a donc une complexité de $\mathcal{O}(Mr^2 + r^3)$ (construction de $A_r(\mu)$ + résolution du système réduit), totalement indépendante de N_{dof} .

4.3 Régularisation

4.3.1 L'obstacle de l'irrégularité

Comme nous l'avons souligné dans la Section 4.2, la méthode EIM repose entièrement sur la régularité des fonctions à approximer. Cependant, la régularité de la fonction de Heaviside n'est pas suffisante pour obtenir un contrôle efficace du terme $(1 + \Lambda_M) \inf_{v \in V_M} \|k - v\|_{L^\infty}$ comme montré dans l'Équation (16). Il est même possible que la quantité $(1 + \Lambda_M) \inf_{v \in V_M} \|k - v\|_{L^\infty}$ ne décroisse pas avec M , rendant l'approche EIM totalement inefficace.

4.3.2 La fonction de Heaviside comme limite de la fonction sigmoïde

Posons :

$$\forall \alpha > 0, \quad \sigma_\alpha : x \mapsto \frac{1}{1 + e^{-\alpha x}}$$

Cette fonction sigmoïde est une approximation lisse (infiniment différentiable) de la fonction de Heaviside H . Le paramètre de raideur α contrôle directement l'étalement spatial de la transition entre les deux états. De plus :

$$\|H - \sigma_\alpha\|_{L^2(\mathbb{R})} = \mathcal{O}\left(\frac{1}{\sqrt{\alpha}}\right)$$




FIGURE 1 – Comparaison entre la fonction d'Heaviside H et une sigmoïde σ_{30} .

Nous pouvons alors à l'aide de ces fonctions sigmoïdes construire pour chaque configuration géométrique de conductivité k une conductivité régularisée :

$$k_\alpha(x, y; \mu_{geo}) = D_{\text{back}} + (D_{\text{frac}} - D_{\text{back}}) \cdot \sigma_\alpha(\mathcal{D}(x, y; \mu_{geo}))$$

Ainsi :

$$\|k - k_\alpha\|_{L^2(\Omega)} \xrightarrow{\alpha \rightarrow +\infty} 0.$$

4.3.3 L'efficacité de l'EIM pour les fonctions lisses

On peut borner théoriquement la constante de Lebesgue Λ_M , inhérente à l'algorithme glouton, par la relation suivante [3] :

$$\Lambda_M \leq 2^{M-1} - 1$$

De plus, pour des fonctions suffisamment régulières (analytiques) telles que les fonctions k_α , il existe des constantes $C_\alpha, \beta_\alpha > 0$ (dépendantes de la raideur α) telles que [5] :

$$\inf_{v \in V_M} \|k_\alpha - v\|_{L^\infty} \leq C_\alpha e^{-\beta_\alpha M}$$

Ainsi, si $\beta_\alpha > \ln 2$ (ce qui est vérifié pour des fonctions suffisamment lisses et donc un α pas trop grand), on a :

$$\|k_\alpha - \mathcal{I}_M[k_\alpha]\|_{L^\infty} \leq (1 + \Lambda_M) \inf_{v \in V_M} \|k_\alpha - v\|_{L^\infty} \leq \frac{C_\alpha}{2} e^{-(\beta_\alpha - \ln 2)M}$$

L'erreur converge ainsi vers zéro exponentiellement vite avec M , garantissant une approximation de haute qualité. Toutefois, notre fonction objectif est toujours k et non pas k_α , nous avons alors l'inégalité triangulaire suivante :

$$\|k - \mathcal{I}_M[k_\alpha]\|_{L^\infty} \leq \|k_\alpha - \mathcal{I}_M[k_\alpha]\|_{L^\infty} + \|k - k_\alpha\|_{L^\infty}$$

Il est alors crucial de choisir une valeur appropriée pour α :

- **Si α est trop grand** : $\beta \leq \ln 2$, et nous perdons le contrôle du terme $\|k_\alpha - \mathcal{I}_M[k_\alpha]\|_{L^\infty}$.
- **Si α est trop petit** : la version lissée k_α est trop loin de la fonction originale k et c'est cette fois-ci le terme $\|k - k_\alpha\|_{L^\infty}$ que nous ne contrôlons plus.

5 Implémentation et validation numérique

Cette section détaille la mise en œuvre pratique du cadre théorique présenté précédemment. L'implémentation a été réalisée en Python, en s'appuyant sur la bibliothèque d'éléments finis *FEniCS* pour la résolution du modèle haute fidélité et l'assemblage des matrices.

Les erreurs ont été évaluées sur un ensemble de test indépendant de $N_{\text{test}} = 50$ configurations paramétriques, tirées aléatoirement dans l'espace des paramètres admissibles.

5.1 Configuration du cas test paramétrique

Afin de valider notre approche, nous avons défini un problème de référence simulant un écoulement de Darcy dans un milieu poreux fracturé.

5.1.1 Maillage et conditions aux limites

Le domaine d'étude Ω est le carré unité $[0, 1]^2$. Il est discrétisé par un maillage régulier de 200×200 éléments triangulaires. En utilisant des éléments finis de Lagrange de degré 2 ($\mathbb{P}_2$), le système discret comporte $N_{\text{dof}} = 80\,402$ degrés de liberté.

Les conditions aux limites de Dirichlet sont imposées pour reproduire un scénario d'injection et de drainage :

$$\bar{u}(x, y) = \begin{cases} 4.0 & \text{si } (x < 0.1 \text{ et } y > 0.9) \\ 1.0 & \text{si } y < 0.1 \\ 0.0 & \text{ailleurs} \end{cases}$$




FIGURE 2 – Visualisation discrète des conditions aux limites imposées sur le bord du domaine.

5.1.2 Espace des paramètres

Le vecteur de paramètres $\mu = (a, x_0, w, D_{\text{back}}, D_{\text{frac}})$ contrôle la géométrie de la fracture (pente, position, largeur) et les conductivités physiques. L'espace admissible μ_{ad} est défini

par les plages suivantes :

$$a \in [20, 60] \quad (\text{pente de la fracture en degrés})$$

$$x_0 \in [50, 90] \quad (\text{position verticale})$$

$$w \in [3, 7] \quad (\text{demi-largeur de la fracture})$$

$$D_{\text{back}} \in [80, 120] \quad (\text{conductivité du milieu de fond})$$

$$D_{\text{frac}} \in [0.5, 2.0] \quad (\text{conductivité de la fracture})$$




FIGURE 3 – Distribution spatiale de la conductivité $K(x, y)$ pour une configuration donnée de la fracture : $a = 40$, $x_0 = 70$, $w = 5$, $D_{\text{back}} = 100$ et $D_{\text{frac}} = 1$.

5.2 Modèle Haute Fidélité et ensemble d'entraînement

La résolution directe du système $A(\mu)\mathbf{u}_h(\mu) = \mathbf{b}(\mu)$ fournit la solution haute fidélité (HDM). La Figure 4 illustre le champ de pression obtenu pour une configuration donnée, où l'on observe clairement l'influence de la fracture sur les lignes de courant.




FIGURE 4 – **Solution de pression du modèle haute fidélité (HDM).** Champ de pression obtenu par éléments finis sur le maillage de référence.

Pour construire la base réduite, la phase *offline* débute par l'échantillonnage de $N_s = 200$ paramètres $\mu^{(i)}$ tirés aléatoirement dans μ_{ad} . Les 200 solutions HDM correspondantes constituent l'ensemble d'entraînement (snapshots). La Figure 5 montre la diversité géométrique capturée par cet ensemble.

Ensemble d'entraînement POD : Exemples de Snapshots




FIGURE 5 – Trois snapshots représentatifs de l'ensemble d'entraînement.

Bien que chaque snapshot soit unique, on observe des motifs communs, ce qui suggère qu'une base réduite de faible dimension pourrait être suffisante pour capturer l'essentiel des informations nécessaires à la reconstruction de la solution pour de nouvelles configurations paramétriques.

5.3 Extraction de la base POD

L'application de la SVD (Décomposition en Valeurs Singulières) sur la matrice des 200 snapshots permet d'extraire les modes optimaux du système.

5.3.1 Analyse spectrale

La Figure 6 illustre la décroissance des valeurs singulières. On observe un effondrement extrêmement rapide (phénomène de coude) : les premières valeurs concentrent la quasi-totalité de l'information. La courbe d'énergie cumulée confirme qu'avec seulement $r = 20$ modes, on capture plus de 99,9% de l'énergie totale du système.




FIGURE 6 – **Spectre singulier et énergie cumulée (200 snapshots).** La décroissance abrupte des valeurs singulières (gauche) confirme la forte compressibilité des solutions de ce problème paramétrique.

5.3.2 Interprétation physique des modes

La Figure 7 affiche les fonctions de base spatiales ϕ_i . Le premier mode capte le gradient de pression macroscopique imposé par les conditions aux limites. Les modes de rang supérieur agissent comme des corrections locales, de plus en plus oscillantes, permettant d'ajuster la solution aux variations spécifiques de la géométrie de la fracture.




FIGURE 7 – **Les 9 premiers modes POD spatiaux.** Le mode 1 représente le profil de pression dominant. Les modes 2 à 9 ajoutent des détails structuraux autour de la zone de fracture paramétrée.

5.4 Performances de la méthode POD (Phase Online)

En projetant le problème sur les r premiers modes, on obtient le modèle réduit. Pour évaluer sa précision, nous avons calculé l'erreur relative commise par rapport à des solutions HDM sur un ensemble de test inédit.

La Figure 8 démontre que l'erreur de projection (tant en norme L^2 qu'en norme énergétique A) décroît exponentiellement avec le nombre de modes. À partir de $r = 20$, l'erreur relative passe sous le seuil de 10^{-4} (0,01%), ce qui valide la précision de l'approximation de Galerkin.




FIGURE 8 – **Convergence de l’erreur du modèle réduit POD.** L’erreur s’effondre exponentiellement, confirmant la prédiction du théorème d’Eckart-Young pour ce problème elliptique.

5.4.1 Le goulot d’étranglement computationnel

Si la réduction de la dimension du système linéaire à 20×20 permet de rendre le temps de *résolution* négligeable, le benchmark révèle un problème majeur : pour chaque nouvelle évaluation de μ , l’assemblage de la matrice réduite $A_r(\mu)$ prend en moyenne 15 millisecondes.

Bien que ce soit 3 fois plus rapide que le modèle HDM complet (~ 50 ms), ce temps est dominé par l’intégration spatiale sur les 80 402 éléments du maillage (complexité en $\mathcal{O}(N_{\text{dof}})$). Ce constat expérimental valide la nécessité d’introduire une méthode d’hyper-réduction pour véritablement dé-corréler le temps de calcul *online* de la finesse du maillage.

5.4.2 Le cas de la dépendance affine

Dans ce test, nous étudions le cas où la géométrie de la fracture est fixée. Les paramètres géométriques sont maintenus constants :

$$a = 40, \quad x_0 = 70, \quad w = 5.$$

Seules les conductivités varient :

$$D_{\text{back}} \in [80, 120], \quad D_{\text{frac}} \in [0.5, 2].$$

Nous générons ainsi un ensemble de $N_s = 50$ snapshots. Ce cas correspond à une dépendance affine en les conductivités, ce qui permet de comparer une POD standard à une POD exploitant directement cette séparation.




FIGURE 9 – Comparaison entre la POD standard et la POD séparée dans le cas affine. La précision reste équivalente, mais la séparation affine réduit fortement le temps de calcul online.

La Figure 9 compare l'erreur en norme A et le temps de calcul pour les deux approches. On observe d'abord que les erreurs obtenues par la POD standard et par la POD séparée sont pratiquement identiques. La séparation affine ne dégrade donc pas la précision du modèle réduit.

En revanche, la différence apparaît nettement sur le temps de calcul. Le temps de la POD standard augmente avec le nombre de modes, car la construction de la matrice réduite reste coûteuse. À l'inverse, le temps de la POD séparée reste très faible et presque constant. Cette différence confirme l'intérêt de la séparation affine : elle permet d'obtenir la même précision tout en réduisant fortement le coût online.




FIGURE 10 – Evolution de la solution approchée en fonction du nombre de modes POD. Quelques modes suffisent à reproduire correctement la solution haute fidélité dans le cas affine.

La Figure 10 montre l'évolution de la solution approchée lorsque le nombre de modes POD augmente. Dès le premier mode, la structure globale du champ de pression est déjà bien capturée. Avec deux puis trois modes, la solution se rapproche davantage de la solution haute fidélité, notamment dans les zones de transition liées à la fracture.

Ces résultats confirment que le cas affine est très favorable à la réduction de modèle. La POD fournit une approximation précise avec peu de modes, et la séparation affine permet de réduire fortement le temps de calcul. Ce cas sert donc de référence avant de traiter le cas général, où la géométrie varie et où la dépendance n'est plus affine.

5.5 Hyper-réduction et performances EIM

5.5.1 Construction de la base EIM

On a collecté $N_G = 400$ snapshots de la conductivité k pour différentes configurations géométriques de fracture. L'application de la SVD sur cette matrice de conductivités a permis d'extraire une base EIM.




FIGURE 11 – **4 modes de la base EIM.** Visualisation des modes principaux extraits par SVD (puis normalisés pour la norme L^∞) des snapshots de conductivité.

5.5.2 Sélection des "magic points" et approximation de la conductivité

L'algorithme glouton a été appliqué pour sélectionner les "magic points". Mais comme précisé dans la Section 4.3, le contrôle de la convergence de l'EIM a été établi pour des fonctions suffisamment régulières, ce qui n'est ici pas le cas à cause de la nature discontinue de la fonction de Heaviside. Comme nous pouvons le voir sur la Figure 12, l'erreur d'approximation de l'EIM reste très mauvaise même pour des nombres de modes élevés, confirmant l'inefficacité de l'approche EIM dans ce cas.




FIGURE 12 – Erreur d'approximation de l'EIM pour la conductivité k .

Cette courbe d'erreur montrant l'inefficacité de l'approche EIM dans ce cas a motivé l'introduction de la régularisation.

5.5.3 Régularisation

Comme expliqué dans la section 4.3, nous avons remplacé la fonction de Heaviside par une fonction sigmoïde lisse, contrôlée par un paramètre de raideur α .




FIGURE 13 – Comparaison entre la conductivité originale k et la conductivité régularisée k_α pour $\alpha = 150$.

La Figure 14 montre la convergence de la conductivité régularisée k_α vers la fonction originale k ainsi que la convergence de la solution de pression HDM associée lorsque α augmente.




FIGURE 14 – Convergence de la conductivité régularisée et de la solution de pression associée vers les fonctions associées au problème de la fracture.

Pour la suite, nous prendrons $\alpha = 150$ qui est une valeur intéressante pour le compromis évoqué à la fin de la section 4.3.3 : la conductivité régularisée k_{150} est suffisamment proche de la fonction originale k , et est suffisamment lisse pour garantir une bonne convergence de l'EIM. Nous avons donc refait des snapshots de conductivité régularisée et ainsi obtenu une nouvelle base pour l'EIM. Et cette fois-ci, on observe une convergence exponentielle de l'erreur d'approximation de l'EIM pour la conductivité régularisée k_α comme étudié dans la section 4.3.3 :




FIGURE 15 – Performance de l'EIM pour reconstruire la conductivité k_α .

Visualisation de la reconstruction de la conductivité k_α par l'EIM :




FIGURE 16 – Visualisation des performances de l'EIM dans le cas régularisé.

5.5.4 Performance finale de l'EIM

À ce stade nous savons que k_{150} est assez proche de k (Figure 13) et nous savons également que k_{150} est bien approché par l'EIM (Figure 15 et 16).

Nous avons ensuite assemblé une nouvelle matrice de snapshots de solution liée à des conductivités régularisées. Et nous en avons récupéré une base réduite de répartition de pression grâce à une POD (comme expliqué section 3.2). Cette base nous permet d'assembler les matrices réduites liées à la base de l'EIM en phase offline et de reconstruire en phase online les solutions comme combinaison linéaire des éléments de cette base réduite.

la Figure 17 étudie les performances obtenues :




FIGURE 17 – Visualisation des performances de l'EIM dans le cas régularisé.

On peut voir Figure 17 que même pour $m = 400$ on garde un temps de calcul 100 fois inférieur à la haute résolution. On observe également que malgré le caractère empirique de l'EIM qui se répercute sur les variations de l'erreur, cette dernière converge bien vers celle obtenue pour la réduction classique avec $r=100$.




FIGURE 18 – Comparaison entre la solution de pression haute fidélité et la solution approchée par l’EIM régularisé pour une configuration de test.

Les performances de l’EIM avec régularisation et assemblage des matrices réduite en phase offline pour traiter le cas de la dépendance non linéaire sont donc satisfaisantes.

6 Conclusion

Ce projet a démontré l’efficacité de la réduction de modèle (ROM) pour accélérer significativement les simulations d’écoulement en milieux poreux fracturés paramétriques. Les contributions principales sont :

6.1 Résumé des résultats

1. **Construction d’une base POD compacte** : Une base de seulement $r = 20$ modes capture 99.9% de l’énergie des 200 snapshots d’entraînement non-linéaires, réduisant la dimensionalité de 80 402 à 20.
2. **Accélération spectaculaire** : Le modèle réduit POD+EIM C^∞ atteint une accélération $\times 62$ par rapport au modèle haute fidélité, avec une erreur relative conservée sous 10^{-3} .
3. **Régularisation par sigmoïde** : Le remplacement de la fonction Heaviside par une transition C^∞ améliore la convergence de l’EIM d’un facteur 3-5 $\times$, réduisant les artefacts numériques et la complexité computationnelle de la phase offline.
4. **Décomposition offline-online** : La formulation EIM affine permet une séparation nette entre une phase offline coûteuse (30 min sur CPU) et une phase online ultra-rapide (0.8 ms par évaluation).

6.2 Implications pratiques

Pour l'ingénierie : Ce ROM peut être intégré dans des workflows interactifs, des interfaces d'optimisation paramétrique, ou des simulations temps-réel. Par exemple :

- **Optimisation de géométrie :** Balayage de 1000+ configurations de fracture en < 1 minute
- **Inversion paramétrique :** Extraction de paramètres de fracture depuis des données de pression observées
- **Analyse de sensibilité :** Quantification de l'impact de chaque paramètre sur la solution

Pour la recherche : Cette approche illustre le potentiel des méthodes ROM pour les problèmes paramétriques non-linéaires. Les techniques déployées (POD, EIM, régularisation) sont transférables à d'autres problèmes d'écoulement en milieux poreux, notamment :

- Milieux fracturés en 3D (extension directe)
- Écoulements diphasiques avec interfaces paramétrées
- Couplages hydromécaniques

6.3 Limitations et perspectives

Limitations du travail actuel :

- Domaine 2D ; extension 3D requiert infrastructure parallèle plus robuste
- Conductivité dépendante uniquement de la géométrie ; les dépendances en temps (problèmes dynamiques) exigent des méthodes POD temporelles (POD-Greedy)
- Absence d'estimateurs d'erreur a posteriori rigoureux ; la validation de précision repose sur une référence obtenue par la méthode des éléments finis et donc déjà avec un certain décalage avec la réalité.

Perspectives futures :

1. **Problèmes instationnaires :** Appliquer POD-Greedy pour construire des bases adaptées temporellement, adaptées aux équations de Darcy dépendantes du temps
2. **Estimation d'erreur certifiée :** Développer des bornes d'erreur a posteriori basées sur la théorie RBM, permettant un assemblage adaptatif du nombre de modes
3. **Couplage multi-physique :** Intégrer des termes de thermolyse, réaction chimique, ou déformation mécanique du milieu
4. **Approches hybrides :** Combiner ROM avec des techniques d'apprentissage machine (neural networks, réseaux convolutifs) pour capturer des dépendances implicites complexes

Références

- [1] Wikipédia. *Loi de Darcy*.
- [2] A. Chatterjee. *An introduction to the proper orthogonal decomposition*. Current Science, 2000.
- [3] M. Barrault, Y. Maday, N. C. Nguyen, et A. T. Patera. An 'empirical interpolation' method: application to efficient reduced-basis discretization of partial differential equations. *Comptes Rendus Mathématique*, 2004.
- [4] I. Berre et al. *Verification benchmarks for single-phase flow in three-dimensional fractured porous media*. 2020.
- [5] L. N. Trefethen. *Approximation Theory and Approximation Practice*. SIAM, 2013.